

ARTICLE

Vision Transformer-Based Postharvest Grading of Chaucha and Chola Potato Varieties

Firstname Lastname¹, Firstname Lastname² and Firstname Lastname^{2,*}

¹Affiliation 1 (Department/School/Faculty/Campus/..., University/...), City, Country

²Affiliation 2, City, Country

*Corresponding Author: Author's Name. Email: author@institute.xxx

Version May 22, 2026 submitted to Journal Not Specified

ABSTRACT: Visual evaluation and manual postharvest classification of tubers present significant limitations in efficiency, cost, and objectivity. Although deep learning has driven advances in agriculture, studies have concentrated on foliar diseases using CNN and YOLO architectures, leaving a gap in the automated classification of tubers. To address this gap, this experimental research develops an attention-based model using the Vision Transformer architecture (ViT-Base/16) to classify chaucha (*Solanum phureja*) and chola (*Solanum tuberosum*) potato tubers at the postharvest stage. Based on the CRISP-ML(Q) methodology, the model was adapted through transfer learning and partial fine-tuning, incorporating techniques such as patch masking and data augmentation. It was trained on a hybrid dataset composed of images from open repositories and locally captured samples under varying lighting conditions and a white background. Performance was evaluated using Precision, Recall, Accuracy, and F1-Score metrics, along with a confusion matrix, while interpretability was analyzed through Grad-CAM attention maps. The model achieved consistent performance metrics across both evaluated categories, reaching an Accuracy of 99.94%, which demonstrates a robust generalization capacity between classes and activation regions coherent with the relevant visual features of the tuber. While ViT-Base/16 is an effective and interpretable model for classifying Andean potatoes, deploying it in real-world scenarios requires optimizing its parameter count and reducing inference times to achieve true scalability in regional agriculture.

KEYWORDS: Pattern recognition; Artificial neural networks; Object recognition; Defect detection; Crops; Inspection.

1 Introduction

La calidad poscosecha de la papa es un factor determinante para su comercialización y competitividad en la cadena agroalimentaria [1,2]. En la práctica, la evaluación visual y la categorización manual de los tubérculos introducen subjetividad, variabilidad entre operarios y limitaciones de escalabilidad en escenarios de alto volumen de clasificación [3,4]. Ante estos desafíos, la visión por computadora y el aprendizaje profundo se han consolidado como alternativas para la inspección automática de calidad y defectos en los tubérculos de papa [1,2,5].

Para automatizar esta inspección, la industria ha empleado Redes Neuronales Convolucionales (CNN); la inspección automatizada de la calidad ha evolucionado desde la detección de defectos superficiales con arquitecturas como Faster R-CNN [6–8], hasta modelos ligeros como Flaw-YOLOv5s [1–3] y *pipelines* híbridos [4,9,10]. Sin embargo, al clasificar variedades andinas con similitudes morfológicas sutiles, como la papa chaucha (*Solanum phureja*) y chola (*Solanum tuberosum*), las arquitecturas convolucionales presentan

limitaciones estructurales [11–16]. Esto se debe a su dependencia de filtros locales, los cuales generan un sesgo inductivo que fragmenta el contexto espacial de la imagen [11,12,17], dificultando la comprensión de la misma en su totalidad y la diferenciación entre defectos morfológicos irregulares frente a texturas atípicas [12,13,18].

La adopción de la arquitectura *Vision Transformer* (ViT) supera esta restricción al modelar dependencias globales desde la primera capa mediante mecanismos de autoatención multi-cabeza (*multi-head self-attention*), los cuales le otorgan una robustez ante variaciones de textura, iluminación heterogénea y oclusiones parciales [8,12,17]. No obstante, ViT exige grandes volúmenes de datos para generalizar sin preentrenamiento. Para compensar esta limitación en dominios con datos escasos, la literatura reciente demuestra que la combinación de preentrenamiento en grandes conjuntos de datos como ImageNet-21k [19], junto con técnicas de aumento de datos y *fine-tuning*, resulta altamente efectiva [15,20,21].

En el sector agrícola, la implementación de técnicas de *transfer learning* y *fine-tuning* sobre arquitecturas de aprendizaje profundo ha demostrado una alta exactitud, principalmente en el diagnóstico de enfermedades foliares [5,22,23]. En este dominio, los modelos basados en *Vision Transformers* (ViT) han alcanzado niveles de exactitud superiores al 98% en la clasificación de enfermedades en hojas de papa [20,23,24]. Asimismo, se ha validado el potencial de enfoques híbridos que integran mecanismos de atención con estructuras residuales para robustecer la extracción de características [9,12,25]. La literatura evidencia que la aplicación de arquitecturas basadas en atención para la inspección directa de la superficie del tubérculo cosechado es aún limitada [2,4,6]. En particular, no se han identificado estudios que empleen *Vision Transformer* (ViT) en la clasificación de variedades andinas como la papa chaucha y la chola bajo condiciones controladas de laboratorio, lo que constituye la brecha que motiva la presente investigación.

Para abordar esta brecha tecnológica, en la presente investigación experimental se evalúa el desempeño del modelo ViT-Base/16 [17], ajustado mediante *Transfer Learning* y *Fine-Tuning* parcial, para la clasificación de tubérculos de papa chaucha y chola en las categorías de “buen estado” y “defectuoso”. A diferencia de los enfoques foliares tradicionales, esta investigación propone un análisis directo de la superficie del tubérculo. En este sentido, las principales contribuciones se enumeran a continuación: i) desarrollar un *dataset* híbrido compuesto por imágenes de repositorios públicos y fotografías locales obtenidas en condiciones controladas para garantizar la representatividad fenotípica y la variabilidad lumínica (Subsecciones 2.1 y 2.2) [1,2,4]; ii) evaluar la robustez del modelo propuesto frente a las imperfecciones de las muestras mediante el análisis de las métricas de *Precision*, *Recall*, *Accuracy* y *F1-Score* (Subsección 2.5) [23,26,27]; y iii) validar la interpretabilidad del modelo mediante la técnica de explicabilidad Grad-CAM (Subsección 2.5) [28,29].

El artículo se estructura de la siguiente manera: la Sección 2 describe el marco metodológico, que comprende la construcción del *dataset* híbrido, la configuración de hiperparámetros, el ajuste del modelo mediante *transfer learning* y *fine-tuning* parcial, el entrenamiento del modelo con técnicas de *patch masking* y *data augmentation*, del mismo modo la evaluación del rendimiento bajo las métricas de *Precision*, *Recall*, *Accuracy* y *F1-Score*; la Sección 3 presenta los resultados obtenidos en la clasificación de los tubérculos de papa chaucha y chola, incluyendo el análisis de la matriz de confusión y la interpretabilidad del modelo a través de mapas de atención Grad-CAM; la Sección 4 discute los hallazgos en relación con las contribuciones planteados, contrastando el desempeño de ViT-Base/16 frente a arquitecturas CNN y YOLO reportadas en la literatura, y examinando la coherencia entre las regiones de activación y las características visuales relevantes del tubérculo; y la Sección 5 expone las conclusiones derivadas de esta investigación, junto con las limitaciones vinculadas a la escalabilidad del modelo y las investigaciones futuras orientadas a reducir el número de parámetros, así como los tiempos de inferencia para su despliegue en contextos agrícolas reales.

2 Methods

La presente investigación adoptó un enfoque experimental siguiendo el marco de trabajo estructurado *CRISP-ML(Q)* [30] para garantizar la reproducibilidad y calidad del modelo de aprendizaje automático propuesto. El proceso se divide en la selección de las muestras de los tubérculos, la adquisición y curación de imágenes, la configuración de hiperparámetros, el ajuste del modelo mediante *Transfer Learning* y *Fine-Tuning* a partir de la arquitectura de transformadores de *Vision Transformer* (ViT), la evaluación de su rendimiento y el análisis de interpretabilidad; el flujo metodológico se presenta en la Figura 1.




Figure 1: Flujo metodológico basado en CRISP-ML(Q) para la clasificación de tubérculos de papa chaucha y chola utilizando Vision Transformer (ViT-Base/16).

2.1 Tuber Samples and Image Acquisition

La investigación se centró en la evaluación poscosecha de tubérculos de papa de las variedades chaucha (*Solanum phureja*) y chola (*Solanum tuberosum*). Se definieron dos categorías fenotípicas de clasificación: “buen estado” (superficie sin defectos visibles) y “defectuoso” (presencia de signos de pudrición, cortes mecánicos o manuales y brotes) [1,2]. Para capturar la variabilidad del mundo real, se construyó un *dataset* híbrido que integra imágenes de repositorios públicos (Potato Disease Recognition Dataset [31], Healthy Potato Image Dataset [32] y Potato Care Dataset [33]) con muestras locales fotografiadas utilizando un dispositivo móvil bajo condiciones de iluminación natural variable y fondo blanco, asegurando la representatividad morfológica de los tubérculos [4].

2.2 Data Processing and Dataset Construction

La curación del conjunto de datos, se implementó un proceso de etiquetado manual apoyado por *scripts* desarrollados en Python, los cuales permitieron organizar las imágenes en directorios correspondientes a cada clase bajo una nomenclatura estandarizada que facilitara su identificación. Este procedimiento hizo posible el descarte de muestras duplicadas, desenfocadas o con variaciones extremas de iluminación que pudieran introducir ruido y comprometer la convergencia del modelo [5]. Asimismo, esta etapa de control durante el preprocesamiento aseguró la consistencia visual y fenotípica de las muestras antes de la división en subconjuntos de datos.

El conjunto final de datos consta de $N = 36\,000$ imágenes, distribuidas de manera balanceada (18 000 imágenes por clase) para prevenir sesgos durante el entrenamiento. Las particiones se establecieron en valores absolutos: 23 040 imágenes para el conjunto de entrenamiento (64%), 5 760 para validación (16%) y 7 200 para el conjunto de prueba (20%).

Previo a la fase de entrenamiento, cada imagen fue redimensionada a una resolución espacial de 224×224 píxeles. Posteriormente, todos los subconjuntos fueron normalizados utilizando la media (0.485, 0.456, 0.406) y la desviación estándar (0.229, 0.224, 0.225) extraídas de ImageNet, unificando la escala de los canales RGB para optimizar la convergencia computacional durante el entrenamiento [34].

Para mejorar la generalización y simular variaciones naturales en las condiciones de captura de campo, se aplicaron técnicas de aumento de datos (*data augmentation*) aleatorias exclusivamente en el conjunto de entrenamiento, incluyendo rotaciones, escalado y variaciones de brillo [20]. Adicionalmente, se implementó una estrategia de enmascaramiento aleatorio de parches (*patch masking*). Esta técnica reduce el sobreajuste al penalizar la dependencia del modelo sobre regiones locales específicas, forzándolo a aprender representaciones semánticas globales y robustas a partir del contexto visible [21].

2.3 ViT-Base/16 Model Architecture

A diferencia de las redes convolucionales convencionales, se implementó la arquitectura Vision Transformer (ViT-Base/16) [17]. Este modelo, preentrenado inicialmente en el conjunto de datos masivo ImageNet-21k [19] y ajustado mediante ImageNet-1K [35], cuenta con un total aproximado de 86 millones de parámetros entrenables. Esta arquitectura procesa la imagen aplanándola en una secuencia de parches no superpuestos de 16×16 píxeles, proyectados linealmente a un espacio vectorial de dimensión $D = 768$. Al integrar un *token* de clasificación ($[CLS]$), el tensor de entrada alcanza dimensiones de $[B, 197, 768]$, donde B es el tamaño del lote.

El procesamiento se basa en bloques codificadores equipados con mecanismos de Autoatención de Múltiples Cabezas (*Multi-Head Self-Attention*), cuya matriz se calcula según la Ecuación 1:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

donde Q, K, V representan Consultas, Claves y Valores, respectivamente, y d_k es la dimensión de las claves. Este mecanismo global es especialmente útil para la inspección de tubérculos, ya que permite al modelo correlacionar simultáneamente anomalías superficiales distantes sin depender del sesgo inductivo local de las CNNs [16,17].

2.4 Experimental Setup

La adaptación del modelo *Vision Transformer* (ViT) a las características morfológicas del tubérculo se llevó a cabo mediante las técnicas de *Transfer Learning* y *Fine-Tuning* parcial. En la primera fase, correspondiente al *Transfer Learning*, se congelaron las capas iniciales del modelo para utilizarlas como extractoras de características globales de la imagen, mientras que la cabeza de clasificación fue reentrenada para discriminar entre las dos clases objetivo: “buen estado” y “defectuoso”. Posteriormente, en la fase de *Fine-Tuning* parcial, se mantuvieron congeladas las seis primeras capas del modelo y se reentrenaron las capas restantes junto con la cabeza de clasificación, con el propósito de ajustar el modelo a las características morfológicas de los tubérculos andinos.

El modelo se entrenó en el entorno de Google Colab mediante el framework de Pytorch utilizando una GPU NVIDIA Tesla T4. Se empleó el optimizador AdamW con una tasa de aprendizaje variable de 1×10^{-5} durante la fase de *Transfer Learning* y 1×10^{-6} para la fase de *Fine-Tuning* parcial, con un tamaño de lote de 32 durante 30 y 20 épocas para cada una de fases, respectivamente.

2.5 Evaluation Metrics and Interpretability

La capacidad predictiva del modelo se evaluó de forma independiente sobre las 7 200 imágenes del conjunto de prueba. Para evaluar el rendimiento, se construyó una matriz de confusión que registra los aciertos y errores del modelo clasificador mediante cuatro componentes fundamentales: Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN). A partir de estos valores, se calcularon las métricas de *Accuracy* (Ecuación 2), *Precision* (Ecuación 3), *Recall* (Ecuación 4) y *F1-Score* (Ecuación 5) [26,27]:

$$\text{Accuracy} = \frac{VP + VN}{VP + FP + VN + FN} \quad (2)$$

$$\text{Precision} = \frac{VP}{VP + FP} \quad (3)$$

$$\text{Recall} = \frac{VP}{VP + FN} \quad (4)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5)$$

Adicionalmente, para otorgar de transparencia agronómica al modelo de clasificación, se empleó la técnica Grad-CAM [28,29]. Esta herramienta de explicabilidad extrae los gradientes de la red y proyecta mapas de calor superpuestos sobre las imágenes, permitiendo verificar de manera cualitativa que el clasificador basa sus decisiones en los defectos correctos (cortes, brotes, pudrición) y no en el ruido del fondo.

3 Results

4 Discussion

5 Conclusions

6 Statements

Acknowledgement: Los autores declaran que utilizaron herramientas de inteligencia artificial generativa (ChatGPT, Gemini, Copilot, NotebookLM y Claude) como apoyo durante la elaboración de este manuscrito. Estas herramientas se emplearon para mejorar la redacción, organizar y formatear el texto, así como para apoyar la extracción y el análisis de información y la validación de la bibliografía utilizada. La interpretación de los resultados, el contenido y las conclusiones de la investigación son responsabilidad exclusiva de los autores.

Funding Statement: Not applicable.

Author Contributions: The authors confirm contribution to the paper as follows: Conceptualization: [Nombre Apellido 1]; Methodology: [Nombre Apellido 1]; Software: [Nombre Apellido 1]; Validation: [Nombre Apellido 1], [Nombre Apellido 2]; Formal analysis: [Nombre Apellido 1]; Investigation: [Nombre Apellido 1]; Data curation: [Nombre Apellido 1]; Writing—original draft preparation: [Nombre Apellido 1]; Writing—review and editing: [Nombre Apellido 1], [Nombre Apellido 2]; Visualization: [Nombre Apellido 1]. All authors reviewed and approved the final version of the manuscript.

Availability of Data and Materials: Part of the data is publicly available and can be accessed at: [Potato Disease Recognition Dataset](#), [PotatoCare: Deep learning based potato disease dataset](#) and [Healthy Potato Image Dataset](#) (accessed on 13 May 2026).

Ethics Approval: Not applicable.

Conflicts of Interest: The authors declare no conflicts of interest.

References

- Wei Q, Zheng Y, Chen Z, Huang Y, Chen C, Wei Z, et al. Nondestructive Perception of Potato Quality in Actual Online Production Based on Cross-Modal Technology. *International Journal of Agricultural and Biological Engineering*. 2023 6;16(6):280-90. doi:10.25165/j.ijabe.20231606.8076.
- Wu H, Zhu R, Wang H, Wang X, Huang J, Liu S. Flaw-YOLOv5s: A Lightweight Potato Surface Defect Detection Algorithm Based on Multi-Scale Feature Fusion. *Agronomy*. 2025 3;15(4):1-17. doi:10.3390/agronomy15040875.
- Divyanth LG, Khanal SR, Paudel A, Mattupalli C, Karkee M. Efficient detection of eyes on potato tubers using deep-learning for robotic high-throughput sampling. *Frontiers in Plant Science*. 2024 12;15:1-13. doi:10.3389/fpls.2024.1512632.
- Hamdi S, Loukil K, Boubaker AH, Snoussi H, Abid M. Hybrid AI Pipeline for Laboratory Detection of Internal Potato Defects Using 2D RGB Imaging. *Journal of Imaging*. 2025 12;11(12):1-24. doi:10.3390/jimaging11120431.
- Shafik W, Tufail A, Liyanage CDS, Apong RAAHM. Using transfer learning-based plant disease classification and detection for sustainable agriculture. *BMC Plant Biology*. 2024 2;24:1-19. doi:10.1186/s12870-024-04825-y.
- Wang C, Xiao Z. Potato surface defect detection based on deep transfer learning. *Agriculture*. 2021 9;11(9):1-17. doi:10.3390/agriculture11090863.
- Lin M, Gao Z, Liao W, Cai H. A Systematic Review of Transformer-Based Vision Models for Object Detection in Food and Agriculture. *Acta Scientiarum Polonorum Technologia Alimentaria*. 2025 8;24(4):489-511. doi:10.17306/J.AFS.001425.
- Nyawose T, Maswanganyi RC, Khumalo P. A Review on the Detection of Plant Disease Using Machine Learning and Deep Learning Approaches. *Journal of Imaging*. 2025 9;11(10):1-37. doi:10.3390/jimaging11100326.
- Meng Q, Guo J, Zhang H, Zhou Y, Zhang X. A dual-branch model combining convolution and vision transformer for crop disease classification. *PLoS ONE*. 2025 4;20(4):1-23. doi:10.1371/journal.pone.0321753.
- Shaheed K, Qureshi I, Abbas F, Jabbar S, Abbas Q, Ahmad H, et al. EfficientRMT-Net—An Efficient ResNet-50 and Vision Transformers Approach for Classifying Potato Plant Leaf Diseases. *Sensors*. 2023 11;23(23):1-22. doi:10.3390/s23239516.
- Raghu M, Unterthiner T, Kornblith S, Zhang C, Dosovitskiy A. Do Vision Transformers See Like Convolutional Neural Networks? *CoRR*. 2022 3;2:1-27. Available from: <https://arxiv.org/abs/2108.08810>.
- Khan S, Naseer M, Hayat M, Zamir SW, Khan FS, Shah M. Transformers in Vision: A Survey. *ACM Computing Surveys*. 2022 1;54(10):1-42. doi:10.1145/3505244.

13. Iwata A, Okuda M. Quantifying Shape and Texture Biases for Enhancing Transfer Learning in Convolutional Neural Networks. *Signals*. 2024 11;5(4):721-35. doi:10.3390/signals5040040. 212
14. Mauricio J, Domingues I, Bernardino J. Comparing Vision Transformers and Convolutional Neural Networks for Image Classification: A Literature Review. *Applied Sciences*. 2023 4;13(9):1-17. doi:10.3390/app13095521. 213
15. Wang Y, Deng Y, Zheng Y, Chattopadhyay P, Wang L. Vision Transformers for Image Classification: A Comparative Survey. *Technologies*. 2025 1;13(1):1-32. Review. doi:10.3390/technologies13010032. 214
16. Liu Y, Zhang Y, Wang Y, Hou F, Yuan J, Tian J, et al. A Survey of Visual Transformers. *IEEE Transactions on Neural Networks and Learning Systems*. 2024;35(6):7478-98. doi:10.1109/TNNLS.2022.3227717. 215
17. Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *arXiv preprint*. 2021 6:1-22. Available from: <https://arxiv.org/abs/2010.11929>. 216
18. Gülmez B. A Comprehensive Review of Convolutional Neural Networks based Disease Detection Strategies in Potato Agriculture. *Potato Research*. 2025;68(2):1295-329. doi:10.1007/s11540-024-09786-1. 217
19. Ridnik T, Ben-Baruch E, Noy A, Zelnik-Manor L. ImageNet-21K Pretraining for the Masses. *arXiv preprint*. 2021 8:1-20. Available from: <https://arxiv.org/abs/2104.10972>. 218
20. Valle-Medina FD, Castillo-Heredia LJ, Correa-Peralta MA, Guzmán-Seraquive JE. Clasificación de enfermedades en hojas de papa utilizando Transformadores de Visión. *Novasinergia Revista Digital de Ciencia, Ingeniería y Tecnología*. 2025 1;8(1):142-56. doi:10.37135/ns.01.15.06. 219
21. shu Peng Y, Wang Y. Optimizing agricultural classification with masked image modeling. *Cogent Food and Agriculture*. 2025 2;11(1):1-16. doi:10.1080/23311932.2025.2462243. 220
22. Paymode AS, Malode VB. Transfer Learning for Multi-Crop Leaf Disease Image Classification using Convolutional Neural Network VGG. *Artificial Intelligence in Agriculture*. 2022 1;6:23-33. doi:10.1016/j.aiia.2021.12.002. 221
23. Alhammad SM, Khafaga DS, El-hady WM, Samy FM, Hosny KM. Deep learning and explainable AI for classification of potato leaf diseases. *Frontiers in Artificial Intelligence*. 2025 2;7:1-9. doi:10.3389/frai.2024.1449329. 222
24. Adhikari S. Advancements in Agricultural Technology: Vision Transformer-Based Potato Leaf Disease Classification. *Journal of Soft Computing Paradigm*. 2024 6;6(2):169-85. doi:10.36548/jscp.2024.2.005. 223
25. Murugavalli S, Gopi R. Plant leaf disease detection using vision transformers for precision agriculture. *Scientific Reports*. 2025 7;15(1):1-17. doi:10.1038/s41598-025-05102-0. 224
26. Chicco D, Jurman G. The Advantages of the Matthews Correlation Coefficient (MCC) over F1-Score and Accuracy in Binary Classification Evaluation. *BMC Genomics*. 2020 1;21(1):1-13. doi:10.1186/s12864-019-6413-7. 225
27. Grandini M, Bagli E, Visani G. Metrics for Multi-Class Classification: an Overview. *arXiv preprint*. 2020 8;1:1-17. Available from: <https://arxiv.org/abs/2008.05756>. 226
28. Selvaraju RR, Cogswell M, Das A, Vedantam R, Parikh D, Batra D. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *arXiv preprint*. 2019 12;4:1-23. Available from: <https://arxiv.org/abs/1610.02391>. 227
29. Fayyaz AM, Abdulkadir SJ, Talpur N, Al-Selwi SM, Hassan SU, Sumiea EH. Grad-CAM (Gradient-weighted Class Activation Mapping): A systematic literature review. *Computers in Biology and Medicine*. 2025 10;198:1-26. doi:10.1016/j.combiomed.2025.111200. 228
30. Studer S, Bui TB, Drescher C, Hanuschkin A, Winkler L, Peters S, et al. Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology. *Machine Learning and Knowledge Extraction*. 2021 4;3(2):392-413. doi:10.3390/make3020020. 229
31. Mafi MMHM, Dipu MMJ, Moazzam MGM, Uddin MS. Potato Disease Recognition Dataset. *Mendeley Data*; 2023. doi:10.17632/pmbc875pr7.1. 230
32. Mridha MH, Mridha NS. Healthy Potato Image Dataset. *Mendeley Data*; 2023. doi:10.17632/5m38z6jthb.1. 231
33. Islam S, Afrin T. PotatoCare: Deep learning based potato disease dataset. *Mendeley Data*; 2025. doi:10.17632/7vm7xskfg4.2. 232
34. Steiner AP, Kolesnikov A, Zhai X, Wightman R, Uszkoreit J, Beyer L. How to train your ViT? Data, Augmentation, and Regularization in Vision Transformers. *Transactions on Machine Learning Research*. 2022 5;2:1-16. Available from: <https://openreview.net/forum?id=4nPswr1KcP>. 233
35. Russakovsky O, Deng J, Su H, Krause J, Satheesh S, Ma S, et al. ImageNet Large Scale Visual Recognition Challenge. *arXiv preprint*. 2015 1:1-43. Available from: <https://arxiv.org/abs/1409.0575>. 234